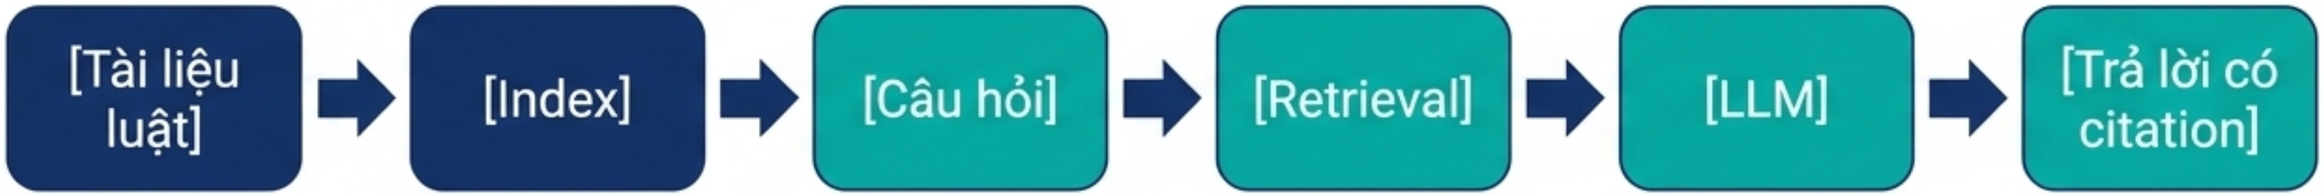
Bài toán và giải pháp Hybrid RAG



Mục tiêu

Hỏi đáp dựa trên tài liệu luật Việt Nam

Đầu vào & Đầu ra

Đầu vào: Câu hỏi của người dùng.

Đầu ra: Câu trả lời kèm trích dẫn nguồn.

Baseline Hệ thống

Kết hợp BM25 + Dense Retrieval + RRF

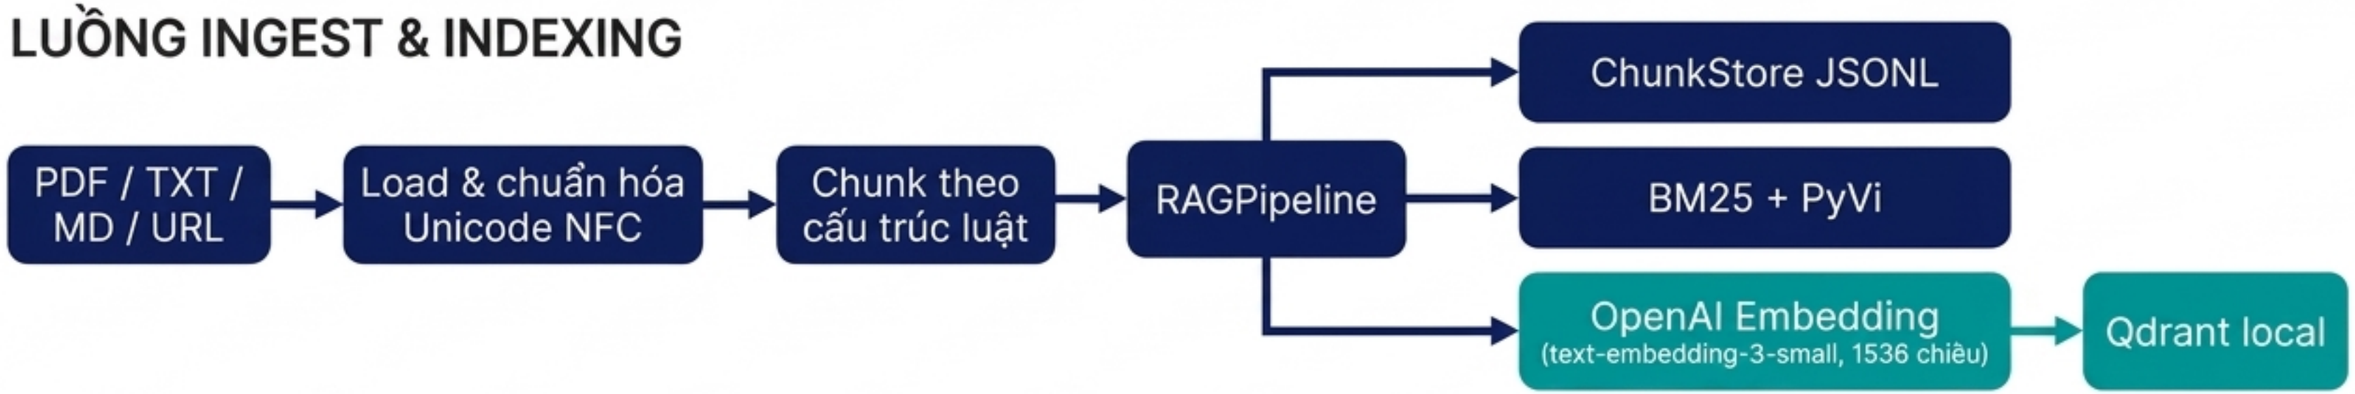
Mở rộng Đánh giá

Tích hợp HyDE và Jev reranking

Gemini Notebook

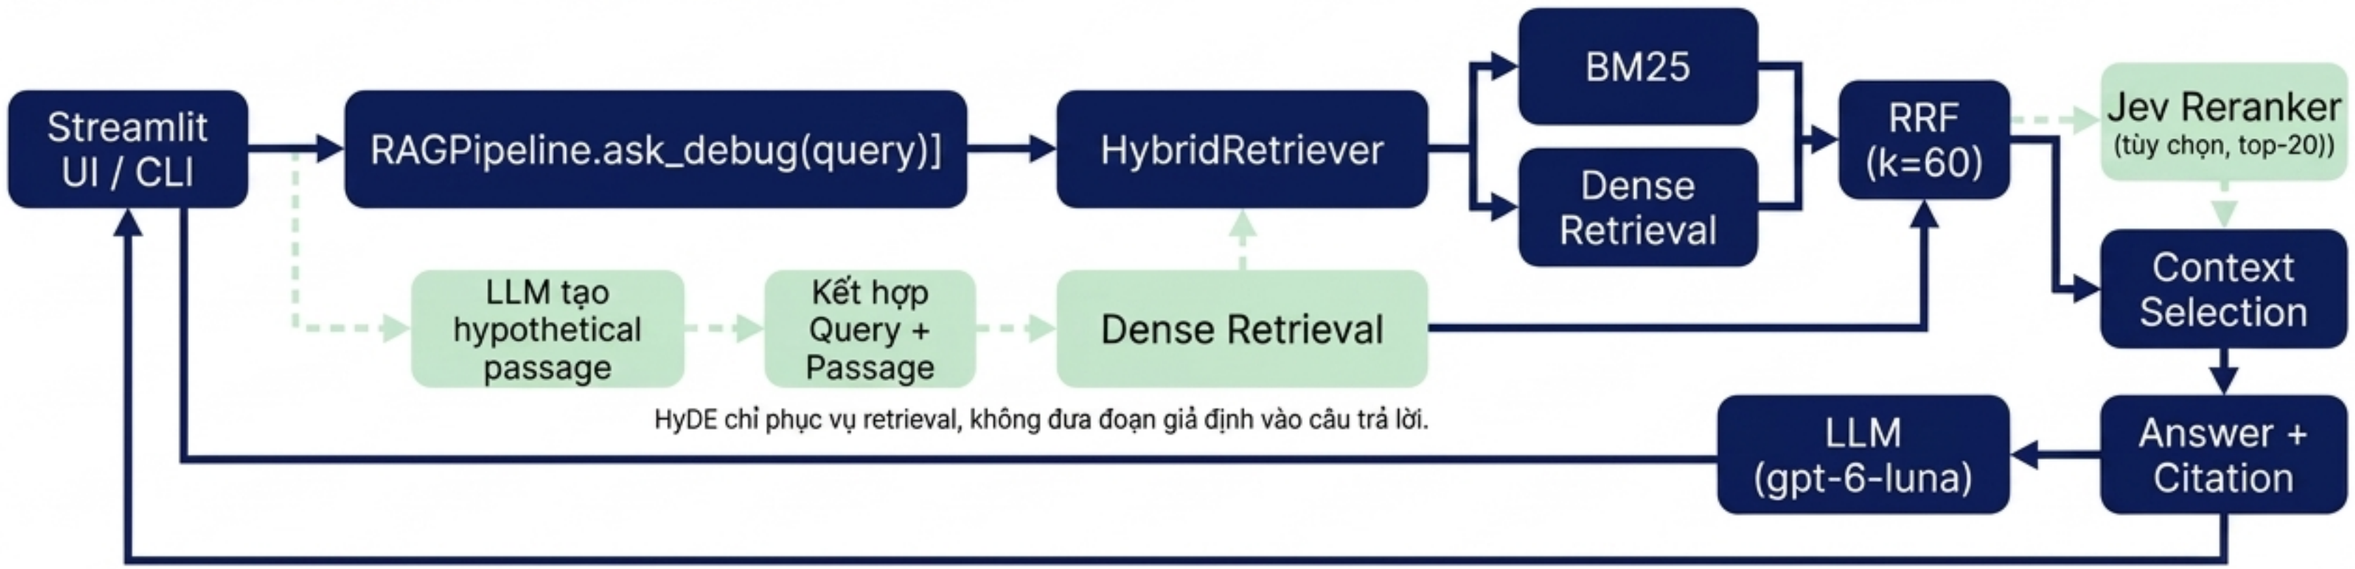
Kiến trúc tổng thể hệ thống

LUỒNG INGEST & INDEXING



BM25 được dựng lại từ ChunkStore khi khởi động; Qdrant lưu vector index.

LUỒNG QUERY & GENERATION



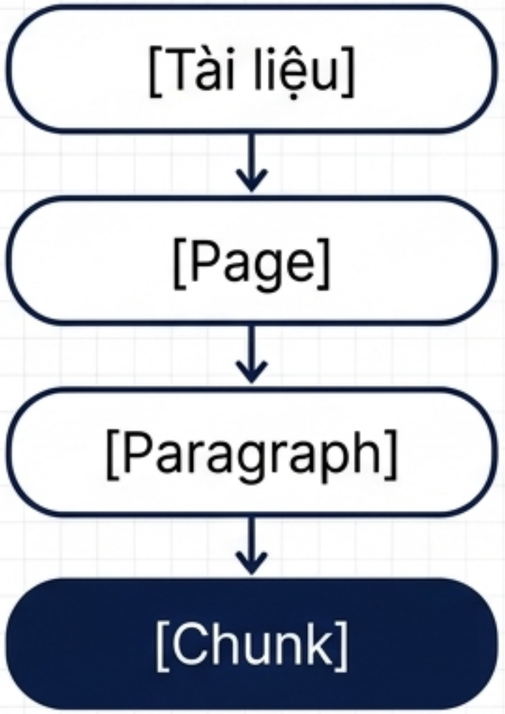
HyDE chỉ phục vụ retrieval, không đưa đoạn giả định vào câu trả lời.

Gemini Notebook

Document Ingestion & Legal-aware Chunking

Bảo toàn cấu trúc và nguồn chứng cứ

Visual Pipeline & Parameters



Công cụ
PyMuPDF (PDF), Trafilatura (URL), UTF-8 (TXT/MD). Chuẩn hóa Unicode NFC và làm sạch khoảng trắng.

Tham số
Tối đa MAX_SYLLABLES=300, overlap một đoạn.

Cấu trúc
Nhận biết hệ thống cấp bậc Phần -> Chương -> Mục -> Điều.

Code Card

Chunk 0042

```
{
  "chunk_id": "0042",
  "source": "bo_luat_lao_dong.pdf",
  "pages": "61-62",
  "section": "Chương IV > Điều 105",
  "text": "..."
}
```

⚠ Hệ thống có cảnh báo với PDF scan không có text; OCR chưa thuộc baseline hiện tại.

Gemini Notebook

Hybrid Retrieval: BM25 + Dense Retrieval

BM25 cho từ khóa, Dense cho ngữ nghĩa

BM25

Text Tách từ tiếng Việt bằng thư viện PyVi

Tham số tối ưu: k1 = 1.5, b = 0.75

Thế mạnh: Tìm kiếm chính xác số Điều, thuật ngữ pháp lý chuyên ngành, và các từ khóa hiếm.

Dense Retrieval

Mô hình: text-embedding-3-small (1.536 chiều)

Lưu trữ: Qdrant local, tính toán bằng cosine similarity

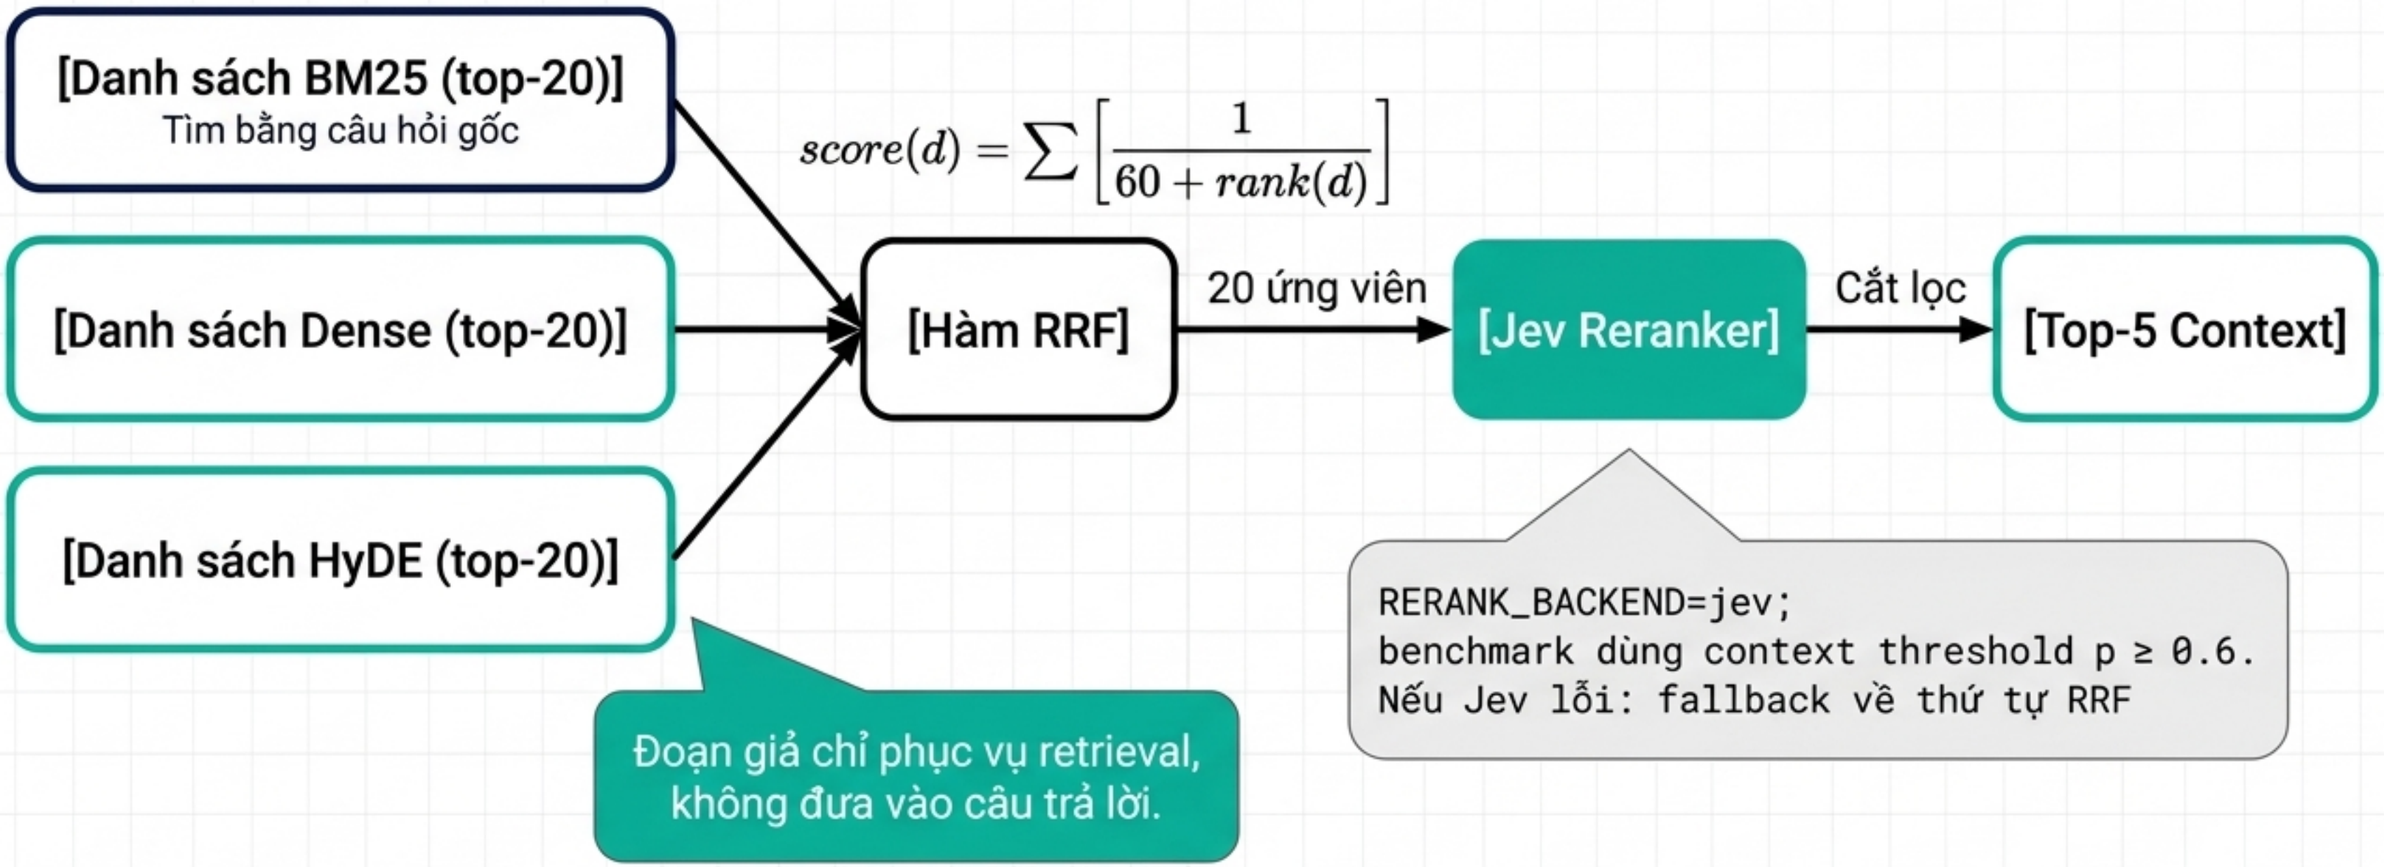
Thế mạnh: Bắt trúng ngữ nghĩa với các câu hỏi diễn đạt đời thường, hoặc paraphrase.

Lưu ý kiến trúc: Không cộng trực tiếp điểm số BM25 với cosine score do khác biệt hệ quy chiếu; hệ thống fusion theo rank bằng RRF.

Gemini Notebook

Mở rộng candidate pool và cải thiện thứ hạng evidence

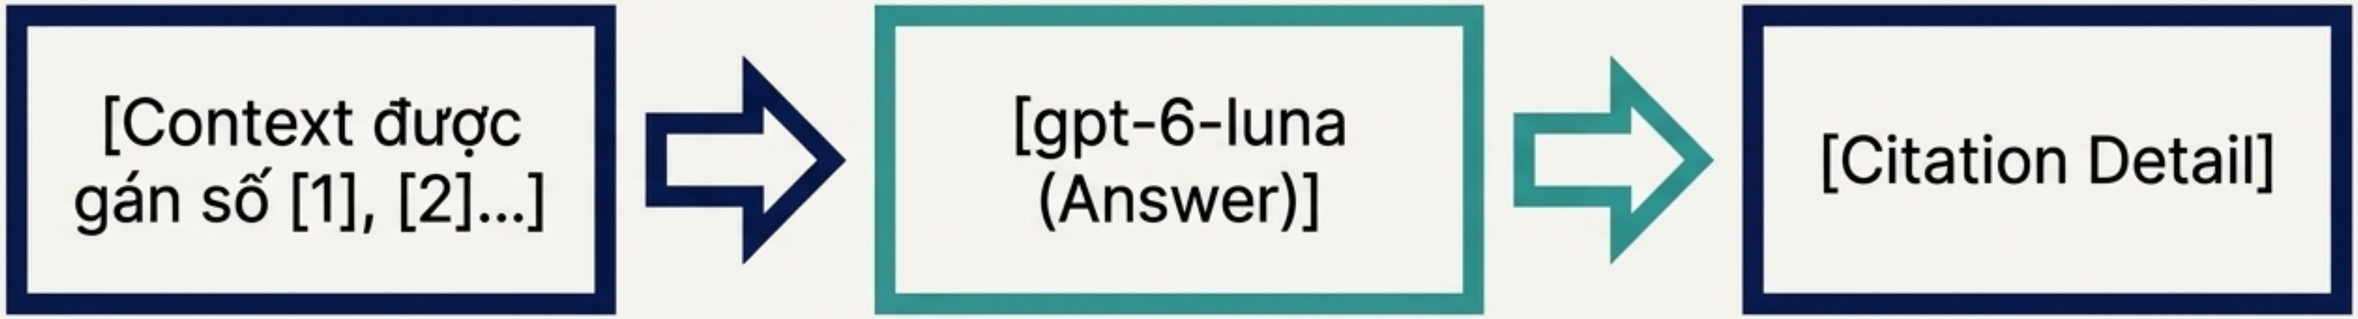
Reciprocal Rank Fusion (RRF), HyDE & Jev



Gemini Notebook

Trả lời dựa trên context có thể truy vết

Generation, Context và Citation



Nếu context rỗng, hệ thống chặn truy vấn, trả về "Không có trong tài liệu" và không gọi LLM.

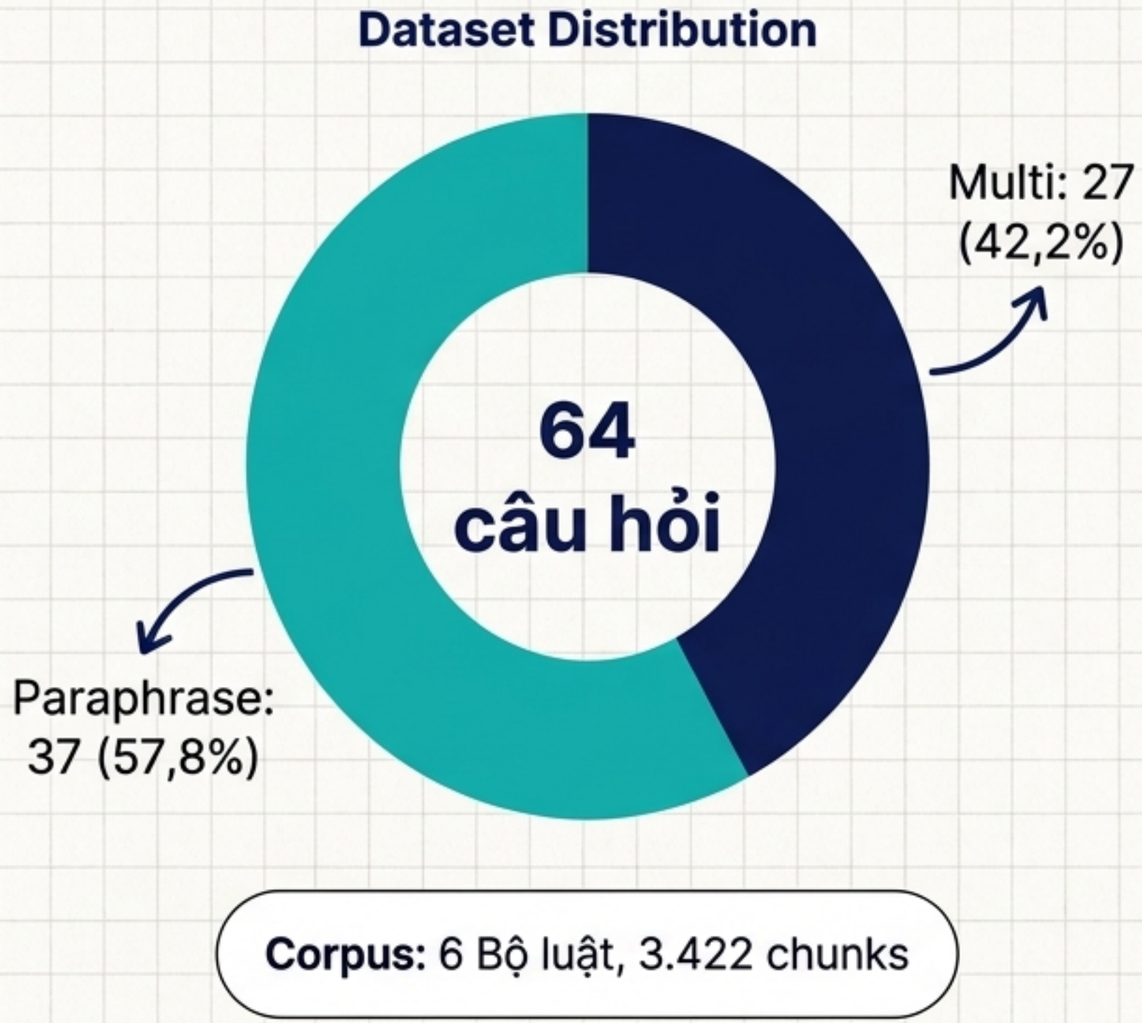
Prompt kiểm soát nghiêm ngặt: LLM bị ép buộc chỉ sử dụng thông tin từ context. Mỗi ý phải có citation [n].

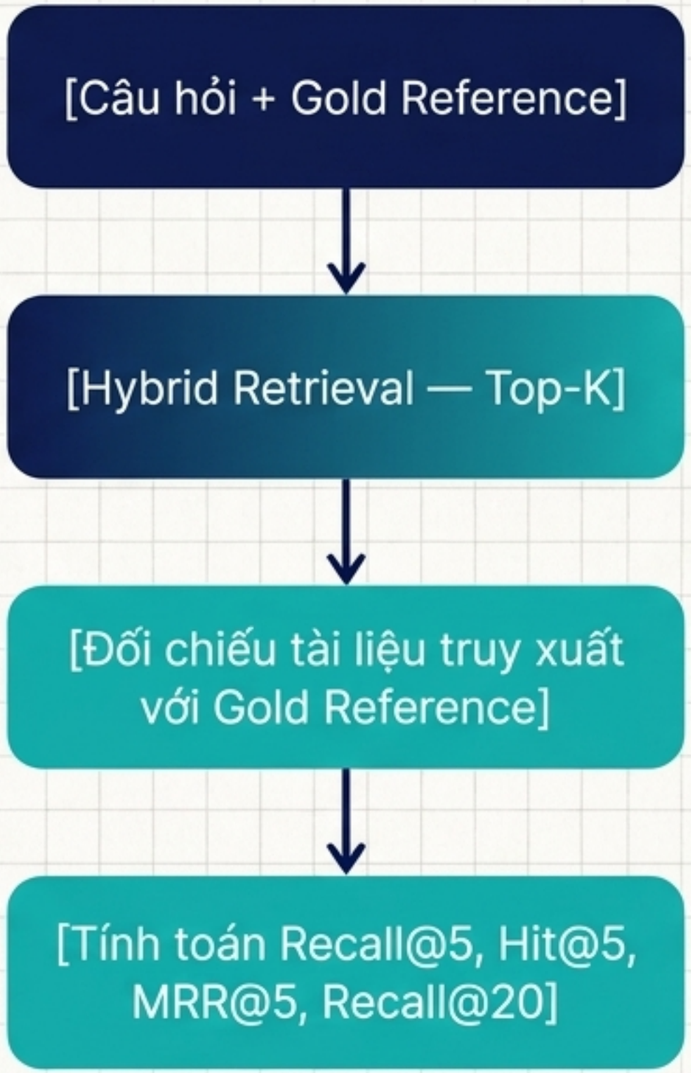
Hiển thị minh bạch: Nguồn · Trang · Trích đoạn ánh xạ chuẩn xác.

⚠ Hiện chưa có guardrail hoàn chỉnh cho ngưỡng RRF trước LLM và tự động từ chối citation không hợp lệ sau khi LLM trả lời.

Gemini Notebook

Benchmark retrieval có gold reference theo nguồn



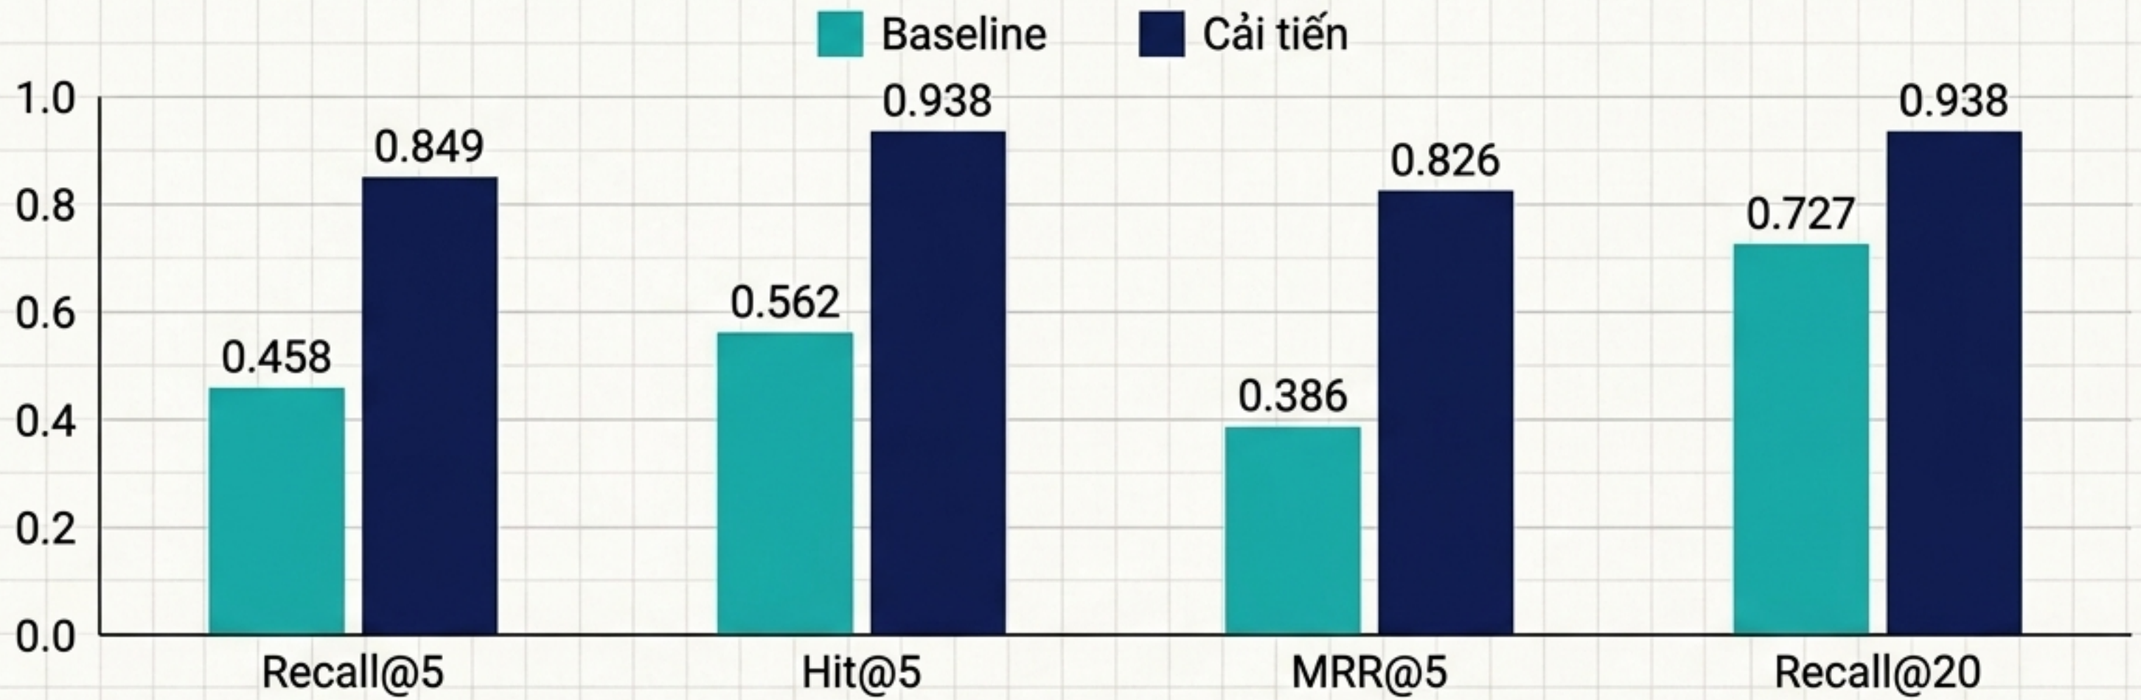


Gold reference được xác định theo source và section/page, không phụ thuộc vào chunk_id.

Gemini Notebook

Đánh giá thực nghiệm: Baseline và cấu hình cải tiến

64 câu hỏi | 6 bộ luật | 3.422 chunks



CẤU HÌNH 1 — BASELINE

Retrieval: Hybrid (BM25 + Dense)
Embedding: jina-embeddings-v5-text-small
LLM: gpt-6-luna
RRF k=60 | Rerank: None | Advanced: None

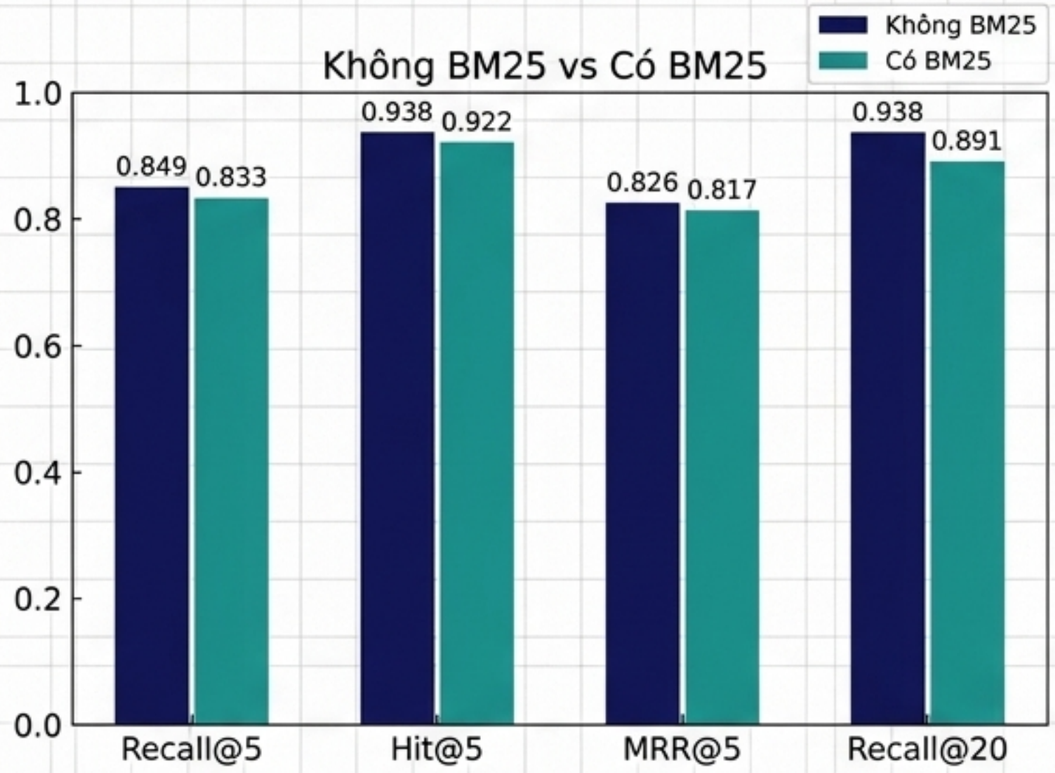
CẤU HÌNH 2 — CẢI TIẾN

Retrieval: Dense (không BM25)
Embedding: jina-embeddings-v5-text-small
LLM: gpt-6-luna
RRF k=60 | Rerank: Jev | Advanced: HyDE

Gemini Notebook

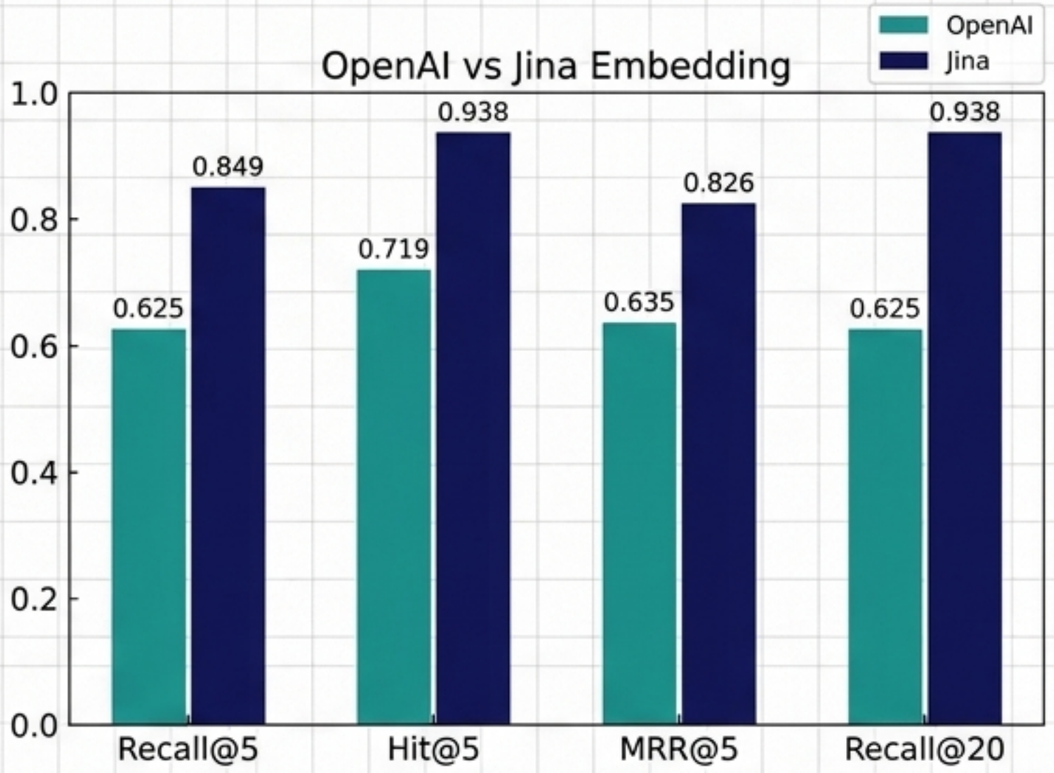
Thực nghiệm 1: Ảnh hưởng của BM25

Embedding: jina-embeddings-v5-text-small
LLM: gpt-6-luna · RRF k=60 · Rerank: Jev · Advanced: HyDE



Thực nghiệm 2: So sánh Embedding Models

LLM: gpt-6-luna · RRF k=60 · Rerank: Jev · Advanced: HyDE



Gemini Notebook

Ưu tiên evidence và reproducibility trước khi mở rộng

Giới hạn hiện tại và Hướng phát triển

Giới hạn hiện tại	Hướng giải quyết tương lai
⚠ Chưa có benchmark out-of-scope	→ ⚙ Thiết lập tập development/test độc lập
⚠ Truy vấn Multi-hop/multi-document còn yếu	→ ⚙ Áp dụng thuật toán Query Decomposition
⚠ Chưa chấm điểm correctness tự động của LLM	→ ⚙ Tích hợp RAGAS và chấm tay có kiểm tra chéo
⚠ Guardrail citation chưa hoàn thiện	→ ⚙ Xây dựng module Validation tự động sau LLM

Nguyên tắc: Sự tồn tại của source code (Contextual Retrieval, SPLADE, ColBERT) không đồng nghĩa với tính năng đã chứng minh hiệu quả nếu chưa có số liệu evaluation.

Gemini Notebook